

# Esercizio 1 - Analisi dei furti di automobili a Chicago

Uberto Vittorio Favero<sup>1,2</sup> and Ludovico Loreti<sup>1,3</sup>

<sup>1</sup>Università di Bologna

<sup>2</sup>Statistica Numerica

10 maggio 2017

## 1 Introduzione

In questa relazione esamineremo il file reso disponibile dal portale della città di Chicago dal 2001 inerente i furti di autoveicoli così da descrivere il campione di dati, analizzarlo formandone un modello.

Il datasource è liberamente scaricabile a: <https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-present/ijzp-q8t2>

Ed è composto da:

- Data e ora di rilievo del reato
- Indirizzo
- Tipologia di reato
- Descrizione del tipo di veicolo
- Descrizione del luogo del furto (Strada, parcheggio privato, supermercato etc)
- Ward, ovvero il distretto di polizia di riferimento
- Community Area, ovvero il quartiere
- Anno
- Latitudine e longitudine

`kruskal.test` help page into a  $\text{\LaTeX}$  document:

## 2 Preparazione dei dati

Il dati sono disponibili per il download in un file .csv di circa 200k record.

Innanzitutto valuto il file con la funzione scan per comprenderne la conformazione:

```
library(ggplot2)
library(stringr)
library(data.table)
library(ggmap)
library(dplyr)

## -----
## data.table + dplyr code now lives in dtplyr.
## Please library(dtplyr)!
## -----
##
## Attaching package: 'dplyr'
## The following objects are masked from 'package:data.table':
##
##   between, first, last
## The following objects are masked from 'package:stats':
##
##   filter, lag
## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

datiChicago <- read.csv('~/Desktop/UNIBO/Statistica /1_2017/dataset/motor_vehicle_theft.csv',
                        stringsAsFactors = FALSE)

str(datiChicago)

## 'data.frame': 295225 obs. of  9 variables:
##  $ Date           : chr  "03/20/2006 11:00:00 PM" "03/15/2006 03:00:00 PM" "03/22/2006 03:00:00 PM" ...
##  $ Block          : chr  "064XX S WOLCOTT AVE" "092XX S LANGLEY AVE" "0000X E 118TH" ...
##  $ Primary.Type    : chr  "MOTOR VEHICLE THEFT" "MOTOR VEHICLE THEFT" "MOTOR VEHICLE THEFT" ...
##  $ Description     : chr  "AUTOMOBILE" "AUTOMOBILE" "THEFT/RECOVERY: AUTOMOBILE" "AUTOMOBILE" ...
##  $ Location.Description: chr  "STREET" "STREET" "STREET" "STREET" ...
##  $ Ward           : int   15  9  9  6  2  43  47  15  4  15 ...
##  $ Community.Area  : int   67  44  53  69  28  8  3  67  38  67 ...
##  $ Year            : int   2006  2006  2006  2006  2006  2005  2006  2006  2006  2006 ...
##  $ Location        : chr   "(41.776711023, -87.671429342)" "(41.72632605, -87.60699981)" ...
```

Ora che ne ho verificato la conformazione posso passare alla valutazione di eventuali dati mancanti

### 3 Analisi quantitativa dei dati

Al fine di fare un'analisi quantitativa dei dati, decido di guardare in generale l'andamento dei furti in Chicago per anno. Quindi appoggiandomi al pacchetto `dplyr` raggruppo il file per anno e calcolo i totali:

```
totAnnuo <- group_by(datiChicago, Year, Description)

totsPerCateg <- summarize(totAnnuo, count=n())

str(totsPerCateg)

## Classes 'grouped_df', 'tbl_df', 'tbl' and 'data.frame': 174 obs. of  3 variables:
## $ Year          : int  2001 2001 2001 2001 2001 2001 2001 2001 2001 2002 ...
## $ Description: chr  "ATT: AUTOMOBILE" "ATT: TRUCK, BUS, MOTOR HOME" "ATTEMPT: CYCLE, SC
## $ count        : int  1439 56 3 20692 220 3228 11 274 1626 1092 ...
## - attr(*, "vars")=List of 1
## ..$ : symbol Year
## - attr(*, "drop")= logi TRUE

#aggrego il dataframe precedente per anno sommandone le categorie -


totPerAnno <- aggregate(totsPerCateg$count, by = list(Year=totsPerCateg$Year), FUN = sum)

#rinomino colonna
names(totPerAnno)[names(totPerAnno) == 'x'] <- 'Totale.annuo'

# xlab - ylab = labels. type = b both (linee e punti)

plot(totPerAnno, ylab = "Tot Annuo", xlab = "Anni",
      main = "Furti totali di veicoli a Chicago dal 2001 a oggi ", type = 'b')
```

**Furti totali di veicoli a Chicago dal 2001 a oggi**



```
print(summary(totPerAnno))
```

```
##      Year      Totale.annuo
##  Min.   :2001   Min.    :  910
## 1st Qu.:2005   1st Qu.:12582
## Median :2009   Median :18881
## Mean   :2009   Mean    :17366
## 3rd Qu.:2013   3rd Qu.:22497
## Max.   :2017   Max.    :27549
```

Analizzando i dati appena stampanti si nota come ci sia un generale calo dei furti. Il dato che fa sorridere è il picco del 2017. Picco comprensibile in quanto l'anno non è ancora terminato.

Sarebbe interessante nei paragrafi successivi stimare i furti di veicoli per quest'anno.

A questo punto il 2017 lo tratto come un outlier e per ora non lo prendo in considerazione, aggiornando i dataset rimuovendo i dati inerenti il 2017, e ricalcolo il **summary**, visualizzando anche mediana, massimo e minimo


```
totsPerCateg <- totsPerCateg[!(totsPerCateg$Year == '2017'),]
totPerAnno <- totPerAnno[!(totPerAnno$Year == '2017'),]

knitr::kable(totPerAnno)
```

Year	Totale.annuo
2001	27549
2002	25121
2003	22748
2004	22805
2005	22497
2006	21818
2007	18573
2008	18881
2009	15482
2010	19028
2011	19387
2012	16492
2013	12582
2014	9913
2015	10076
2016	11363

```
plot(totPerAnno, ylab = "Tot Annuo", xlab = "Anni",
      main = "Furti totali di veicoli a Chicago dal 2001 a oggi ", type = 'b')
```

**Furti totali di veicoli a Chicago dal 2001 a oggi**



Ora, per studiare i dati in maniera più consona, calcolo le somme mensili per ogni tipologia di furto. Ma per fare questo per evitare errori sui formati di data, converto la colonna **Date** secondo lo standard POSIXct - mentre ora sono salvati in POSIXlt. Successivamente creo una tabella con le righe contenenti sulla prima colonna una sequenza di numeri dal 2001 al 2017 ordinati in maniera crescente divisi separati da un intervallo di 1/12 e calcolo per ogni mese i totali per ciascuno delle tipologie di furto indicate. Per terminare salvo il csv così da poterlo riutilizzare successivamente

```
Sys.setenv(TZ='America/Sao_Paulo')

datiChicago$Date <- as.POSIXct(datiChicago$Date, tz="GMT", format="%m/%d/%Y %I:%M:%S %p")
#creo una tabella vuota dove la prima colonna sono gli anni dal 2006 a oggi in forma numerica 2006, 2006.08333-...
monthlyByCateg <- data.frame(Months =seq(as.Date("2001-01-01"),
                                         as.Date("2017-01-01"), by="months" ))
```

```

#monthlyByCateg <- data.frame(Months = seq(from = 2001, to = 2017, by= 1/12 ))
descrizioni <- as.character(unique(unlist(datiChicago$Description)))
#genero la matrice con dati vuoti
monthlyByCateg[,descrizioni] <-NA

anno = 2001
mese = 1
rowsTot = nrow(monthlyByCateg)
categTot <- length(descrizioni)
#descrizione vale come indice colonna per la matrice monthlyByCa-
teg

for(riga in 1: rowsTot){
  #so fare due nested for, ma mi serviva così. ci mette 3 minuti buo-
  ni a calcolare tutto
  monthlyByCateg[riga, 2] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[1] & month(Dat
monthlyByCateg[riga, 3] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[2] & month(Dat
monthlyByCateg[riga, 4] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[3] & month(Dat
monthlyByCateg[riga, 5] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[4] & month(Dat
monthlyByCateg[riga, 6] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[5] & month(Dat
monthlyByCateg[riga, 7] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[6] & month(Dat
monthlyByCateg[riga, 8] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[7] & month(Dat
monthlyByCateg[riga, 9] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[8] & month(Dat
monthlyByCateg[riga, 10] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[9] & month(Da
monthlyByCateg[riga, 11] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[10] & month(D
monthlyByCateg[riga, 12] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[11] & month(D
monthlyByCateg[riga, 13] <- summarize(subset(datiChicago, Year == anno
                                              & Description == descrizioni[12] & month(D

  mese = mese+1
  if(riga %% 12 == 0){
    anno = anno +1
    mese = 1
  }
}

```

```

}

write.csv(monthlyByCateg, file = "monthlyByCateg.csv")
#rinomino colonna
names(monthlyByCateg)[names(monthlyByCateg) == 'Months'] <- 'time'

knitr::kable(summary(monthlyByCateg))

```

time	AUTOMOBILE	THEFT/RECOVERY: AUTOMOBILE	TRUCK, BUS, MOTOR HOME
Min. :2001-01-01	Min. : 550	Min. : 31.0	Min. : 8.0
1st Qu.:2005-01-01	1st Qu.: 897	1st Qu.: 65.0	1st Qu.: 37.0
Median :2009-01-01	Median :1246	Median : 86.0	Median :139.0
Mean :2008-12-30	Mean :1191	Mean :111.2	Mean :125.6
3rd Qu.:2013-01-01	3rd Qu.:1430	3rd Qu.:153.0	3rd Qu.:191.0
Max. :2017-01-01	Max. :2296	Max. :372.0	Max. :281.0

A questo punto posso creare una funzione che mi gestisce le varie colonne e mi stampa un summary

```

analisiDescr <- function(file, colStart, colEnd){
  dataset <- file[,colStart:colEnd]
  dim <- length(dataset)
  #2 significa colonne, #1 righe
  media <- apply(dataset, 2, mean, na.rm = TRUE)
  varianza <- apply(dataset, 2, var, na.rm = TRUE)
  devStd <- sqrt(varianza)
  minimo <- apply(dataset, 2, min, na.rm = TRUE)
  massimo <- apply(dataset, 2, max, na.rm = TRUE)
  Desc <- data.frame(media, varianza, devStd, minimo, massimo)
  colnames <- c("media", "varianza", "devStd", "minimo", "massimo")
  return(Desc)
}

dati <- analisiDescr(monthlyByCateg, 2, 13)
dati

```

```

##              media      varianza
## AUTOMOBILE      1.190508e+03 1.018440e+05
## THEFT/RECOVERY: AUTOMOBILE      1.111969e+02 4.053024e+03
## TRUCK, BUS, MOTOR HOME      1.256425e+02 6.000668e+03
## ATT: AUTOMOBILE      5.560104e+01 7.423244e+02
## THEFT/RECOVERY: TRUCK,BUS,MHOME      1.428497e+01 1.309444e+02
## CYCLE, SCOOTER, BIKE W-VIN      2.438860e+01 3.747701e+02
## ATT: TRUCK, BUS, MOTOR HOME      5.927461e+00 2.306763e+01
## THEFT/RECOVERY: CYCLE, SCOOTER, BIKE NO VIN      5.181347e-02 4.938472e-02
## ATTEMPT: CYCLE, SCOOTER, BIKE W-VIN      4.611399e-01 5.102008e-01
## THEFT/RECOVERY: CYCLE, SCOOTER, BIKE W-VIN      9.792746e-01 1.770402e+00

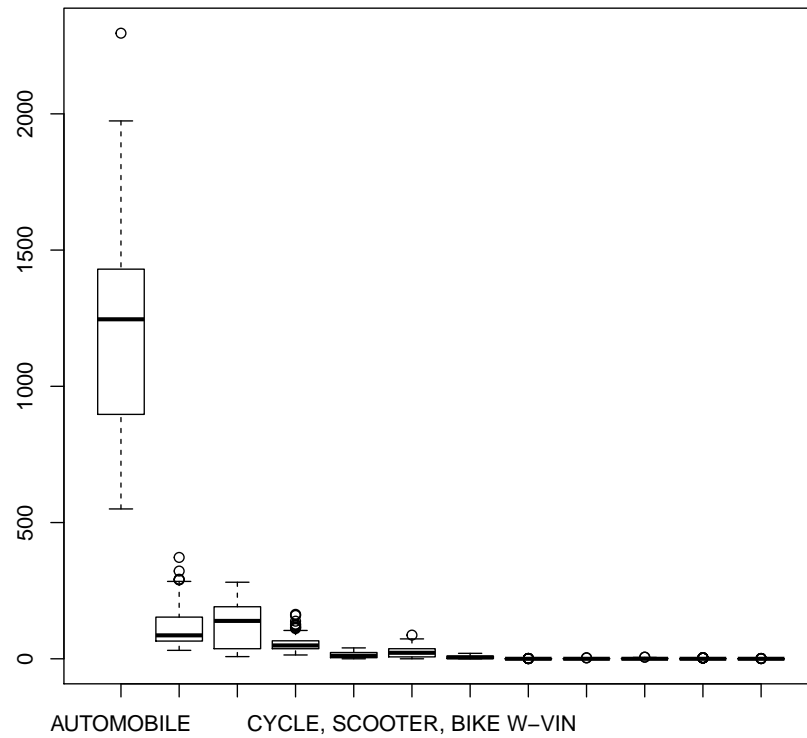
```



## CYCLE, SCOOTER, BIKE NO VIN	5.906736e-01	9.930376e-01	
## ATTEMPT: CYCLE, SCOOTER, BIKE NO VIN	3.108808e-02	3.027850e-02	
##		devStd	minimo massimo
## AUTOMOBILE	319.1300042	550	2296
## THEFT/RECOVERY: AUTOMOBILE	63.6633610	31	372
## TRUCK, BUS, MOTOR HOME	77.4639813	8	281
## ATT: AUTOMOBILE	27.2456304	14	163
## THEFT/RECOVERY: TRUCK,BUS,MHOME	11.4430944	0	40
## CYCLE, SCOOTER, BIKE W-VIN	19.3589793	0	87
## ATT: TRUCK, BUS, MOTOR HOME	4.8028770	0	20
## THEFT/RECOVERY: CYCLE, SCOOTER, BIKE NO VIN	0.2222267	0	1
## ATTEMPT: CYCLE, SCOOTER, BIKE W-VIN	0.7142834	0	4
## THEFT/RECOVERY: CYCLE, SCOOTER, BIKE W-VIN	1.3305644	0	6
## CYCLE, SCOOTER, BIKE NO VIN	0.9965127	0	4
## ATTEMPT: CYCLE, SCOOTER, BIKE NO VIN	0.1740072	0	1


Dall'analisi dei dati notiamo che i dati sui furti di automobili (come quelli di mezzi pesanti) variano notevolmente. Studio quindi la presenza di outliers. Piccola osservazione: se vi rubano un mezzo a Chicago non sperate di recuperarlo, sciocchi.

```
furti <- boxplot(x= as.list(monthlyByCateg[,2:13]))
```




Come si evince dal grafico ci sono degli outliers potenziali soprattutto nei grafici 1, 2, 4 e 6 che, mi accingo a rimuovere tramite `identify`, che fornisce la possibilità di intervenire direttamente col mouse sul grafico.

```
furtiAuto <- boxplot(x= monthlyByCateg$AUTOMOBILE)
darimuovere <- identify(rep(3, length(monthlyByCateg[,2]))+ monthlyByCateg[2])
```



```
boxplot( totPerAnno$Totale.annuo)
```




Sarò sincero... la funzione "identify" mi ha sempre risposto **warning: no point within 0.25 inches** nonostante cliccassi correttamente sul punto outlier segnalato, al che ho proceduto alla rimozione manuale dell'outlier, corrispondente alla misurazione su Ottobre 2001.

Ora studiamo i file come time-series. Il formato TimeSeries permette tutta una serie di analisi sul trend e sulle previsioni grazie alle funzionalità built-in di R. Pertanto converto il dataset tramite la funzione in una serie temporale che ha una ciclicità di 12 mesi. Successivamente applico la funzione decompose che mi permette di studiare la serie temporale stessa.

```
timeSerie <- ts(select(monthlyByCateg, AUTOMOBILE), frequency = 12, start = c(2001,1) )
timeSerieDec <- decompose(timeSerie, type = "multiplicative")
plot(timeSerieDec)
```

### Decomposition of multiplicative time series



Questo grafico, tramite l'analisi di una serie temporale (`timeserie`) mostra:

- Andamento dell'osservazione
- Il trend, che abbastanza assimilabile a un processo lineare
- Stagionalità. Come vediamo c'è una certa ripetitività nel fenomeno e quindi sì, il fenomeno è stagionale (o meglio, nel grafico è annuale)
- Random, ovvero la stima dei dati che non seguono l'andamento (componenti irregolari)

Da una `timeserie` e il relativo andamento risulta abbastanza agevole lavorare sulle stime per la creazione di un modello Utilizzando una previsione di Holt,

```
serieFurti <- HoltWinters(timeserie, beta = FALSE, gamma = FALSE)
serieFurti$fitted
```

##			xhat	level
##	Feb	2001	1518.0000	1518.0000
##	Mar	2001	1353.6806	1353.6806
##	Apr	2001	1479.3141	1479.3141
##	May	2001	1493.8587	1493.8587
##	Jun	2001	1499.3190	1499.3190
##	Jul	2001	1611.7812	1611.7812
##	Aug	2001	1840.6337	1840.6337
##	Sep	2001	1812.0397	1812.0397
##	Oct	2001	1920.6651	1920.6651
##	Nov	2001	2172.3990	2172.3990
##	Dec	2001	1969.5826	1969.5826
##	Jan	2002	1855.1743	1855.1743
##	Feb	2002	1705.4932	1705.4932
##	Mar	2002	1527.4292	1527.4292
##	Apr	2002	1588.8449	1588.8449
##	May	2002	1576.2058	1576.2058
##	Jun	2002	1532.4728	1532.4728
##	Jul	2002	1466.4279	1466.4279
##	Aug	2002	1652.5932	1652.5932
##	Sep	2002	1693.7782	1693.7782
##	Oct	2002	1615.4561	1615.4561
##	Nov	2002	1661.4279	1661.4279
##	Dec	2002	1564.5613	1564.5613
##	Jan	2003	1423.3396	1423.3396
##	Feb	2003	1347.9944	1347.9944
##	Mar	2003	1220.5668	1220.5668
##	Apr	2003	1297.3162	1297.3162
##	May	2003	1378.2578	1378.2578
##	Jun	2003	1412.9608	1412.9608
##	Jul	2003	1394.8784	1394.8784
##	Aug	2003	1437.8842	1437.8842
##	Sep	2003	1440.6446	1440.6446
##	Oct	2003	1458.3210	1458.3210
##	Nov	2003	1427.2539	1427.2539
##	Dec	2003	1419.7060	1419.7060
##	Jan	2004	1435.9998	1435.9998
##	Feb	2004	1360.8825	1360.8825
##	Mar	2004	1303.2818	1303.2818
##	Apr	2004	1404.3672	1404.3672
##	May	2004	1426.9244	1426.9244
##	Jun	2004	1436.3648	1436.3648
##	Jul	2004	1444.1684	1444.1684
##	Aug	2004	1470.2124	1470.2124
##	Sep	2004	1462.0217	1462.0217

```

## Oct 2004 1395.6087 1395.6087
## Nov 2004 1390.5056 1390.5056
## Dec 2004 1381.4475 1381.4475
## Jan 2005 1414.0113 1414.0113
## Feb 2005 1332.1793 1332.1793
## Mar 2005 1242.1864 1242.1864
## Apr 2005 1360.7738 1360.7738
## May 2005 1315.3185 1315.3185
## Jun 2005 1368.7602 1368.7602
## Jul 2005 1361.5434 1361.5434
## Aug 2005 1308.8650 1308.8650
## Sep 2005 1334.4418 1334.4418
## Oct 2005 1328.7800 1328.7800
## Nov 2005 1493.9176 1493.9176
## Dec 2005 1454.4021 1454.4021
## Jan 2006 1531.2619 1531.2619
## Feb 2006 1542.4880 1542.4880
## Mar 2006 1371.1344 1371.1344
## Apr 2006 1355.6183 1355.6183
## May 2006 1292.1586 1292.1586
## Jun 2006 1401.3749 1401.3749
## Jul 2006 1431.3046 1431.3046
## Aug 2006 1396.8950 1396.8950
## Sep 2006 1423.1224 1423.1224
## Oct 2006 1304.3279 1304.3279
## Nov 2006 1279.2924 1279.2924
## Dec 2006 1226.7824 1226.7824
## Jan 2007 1240.3422 1240.3422
## Feb 2007 1246.1489 1246.1489
## Mar 2007 1105.2038 1105.2038
## Apr 2007 1155.3690 1155.3690
## May 2007 1145.0611 1145.0611
## Jun 2007 1202.6996 1202.6996
## Jul 2007 1211.6201 1211.6201
## Aug 2007 1187.7300 1187.7300
## Sep 2007 1250.9561 1250.9561
## Oct 2007 1178.5509 1178.5509
## Nov 2007 1274.7610 1274.7610
## Dec 2007 1163.5865 1163.5865
## Jan 2008 1194.0449 1194.0449
## Feb 2008 1163.1630 1163.1630
## Mar 2008 1045.0120 1045.0120
## Apr 2008 1185.1785 1185.1785
## May 2008 1155.5483 1155.5483
## Jun 2008 1151.1564 1151.1564

```

```

## Jul 2008 1241.5949 1241.5949
## Aug 2008 1434.3550 1434.3550
## Sep 2008 1459.6032 1459.6032
## Oct 2008 1338.4742 1338.4742
## Nov 2008 1214.7489 1214.7489
## Dec 2008 1082.7911 1082.7911
## Jan 2009 1077.5657 1077.5657
## Feb 2009 1032.2500 1032.2500
## Mar 2009 958.3062 958.3062
## Apr 2009 968.1612 968.1612
## May 2009 919.0926 919.0926
## Jun 2009 880.8011 880.8011
## Jul 2009 891.6656 891.6656
## Aug 2009 963.6539 963.6539
## Sep 2009 983.3361 983.3361
## Oct 2009 1030.0591 1030.0591
## Nov 2009 1132.6352 1132.6352
## Dec 2009 1154.3420 1154.3420
## Jan 2010 1215.8162 1215.8162
## Feb 2010 1259.5344 1259.5344
## Mar 2010 1009.6788 1009.6788
## Apr 2010 1080.3168 1080.3168
## May 2010 1123.6993 1123.6993
## Jun 2010 1304.9877 1304.9877
## Jul 2010 1236.5854 1236.5854
## Aug 2010 1252.9601 1252.9601
## Sep 2010 1284.5093 1284.5093
## Oct 2010 1378.0645 1378.0645
## Nov 2010 1426.9817 1426.9817
## Dec 2010 1459.1872 1459.1872
## Jan 2011 1543.5688 1543.5688
## Feb 2011 1522.3959 1522.3959
## Mar 2011 1207.5761 1207.5761
## Apr 2011 1304.4400 1304.4400
## May 2011 1355.1174 1355.1174
## Jun 2011 1420.0957 1420.0957
## Jul 2011 1440.1523 1440.1523
## Aug 2011 1405.8449 1405.8449
## Sep 2011 1290.5900 1290.5900
## Oct 2011 1194.9561 1194.9561
## Nov 2011 1198.3390 1198.3390
## Dec 2011 1251.0963 1251.0963
## Jan 2012 1248.3489 1248.3489
## Feb 2012 1253.4804 1253.4804
## Mar 2012 1096.8871 1096.8871

```



```


## Apr 2012 1161.3492 1161.3492
## May 2012 1143.6770 1143.6770
## Jun 2012 1207.6093 1207.6093
## Jul 2012 1233.3576 1233.3576
## Aug 2012 1191.5349 1191.5349
## Sep 2012 1149.5933 1149.5933
## Oct 2012 1104.9297 1104.9297
## Nov 2012 1156.6201 1156.6201
## Dec 2012 1209.1888 1209.1888
## Jan 2013 1235.2192 1235.2192
## Feb 2013 1273.9723 1273.9723
## Mar 2013 1176.7406 1176.7406
## Apr 2013 1028.6918 1028.6918
## May 2013 862.5670 862.5670
## Jun 2013 815.9090 815.9090
## Jul 2013 852.8581 852.8581
## Aug 2013 848.9291 848.9291
## Sep 2013 851.6594 851.6594
## Oct 2013 799.5739 799.5739
## Nov 2013 779.7389 779.7389
## Dec 2013 748.3915 748.3915
## Jan 2014 817.2102 817.2102
## Feb 2014 751.3414 751.3414
## Mar 2014 651.8501 651.8501
## Apr 2014 745.8474 745.8474
## May 2014 658.0892 658.0892
## Jun 2014 619.1293 619.1293
## Jul 2014 699.5255 699.5255
## Aug 2014 722.6473 722.6473
## Sep 2014 698.0683 698.0683
## Oct 2014 700.7052 700.7052
## Nov 2014 733.0961 733.0961
## Dec 2014 710.8988 710.8988
## Jan 2015 657.9821 657.9821
## Feb 2015 702.9304 702.9304
## Mar 2015 600.3613 600.3613
## Apr 2015 653.7743 653.7743
## May 2015 619.7204 619.7204
## Jun 2015 662.8322 662.8322
## Jul 2015 726.6604 726.6604
## Aug 2015 728.9003 728.9003
## Sep 2015 766.5259 766.5259
## Oct 2015 737.3334 737.3334
## Nov 2015 724.3667 724.3667
## Dec 2015 720.0966 720.0966

```

```
## Jan 2016 756.2492 756.2492
## Feb 2016 820.4684 820.4684
## Mar 2016 757.1093 757.1093
## Apr 2016 698.0151 698.0151
## May 2016 671.8480 671.8480
## Jun 2016 703.4724 703.4724
## Jul 2016 766.8713 766.8713
## Aug 2016 823.9664 823.9664
## Sep 2016 832.7079 832.7079
## Oct 2016 799.3692 799.3692
## Nov 2016 827.2906 827.2906
## Dec 2016 833.1319 833.1319
## Jan 2017 956.4507 956.4507
```

```
plot(serieFurti)
```

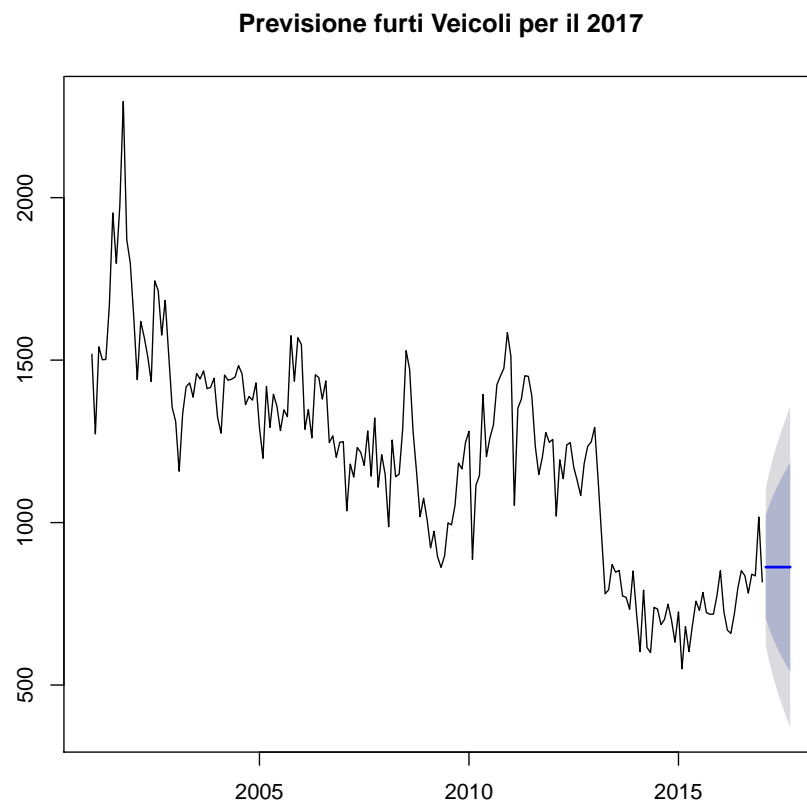
### Holt-Winters filtering



```
require(forecast)

## Loading required package: forecast

serieFurti2 <- forecast::forecast.HoltWinters(serieFurti, h = 8)
plot(serieFurti2, main = "Previsione furti Veicoli per il 2017")
```



```
acf(serieFurti2$residuals, lag.max = 20)

## Error in na.fail.default(as.ts(x)): missing values in object
```

La stima di Holt, (1957) ci permette di prevedere l'andamento del fenomeno preso in esame utilizzando 3 equazioni:

Una equazione per la previsione:

$$\hat{y}_{t+h|t} = l_t + hb_t$$

Una equazione di smoothing per il livello:

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1})$$

Una equazione di smoothing per il trend:

$$b_t = \beta^*(l_t - l_{t-1}) + (1 + \beta^*)b_{t-1}$$

## 4 Analisi delle distribuzioni

Analizzo la correlazione

```
corr
```

```
## Error in eval(expr, envir, enclos):  oggetto "corr" non trovato
```

La mia analisi ora vuole spostarsi sui giorni (e le relative ore) al fine di valutare tramite un grafico heat, quali siano le ore più rischiose.

```
par(mfrow = c(2,2))
```

```
y <- c("Fn(Auto)", "Fn(RD)", "Fn(ROE)")
x <- c("Auto", "Ritrovamenti", "ROE")
```

```
plot(ecdf(monthlyByCateg[,2]), main = "Auto", xlab = x[1], ylab = y[1])
plot(ecdf(monthlyByCateg[,3]), main = "Attempted auto", xlab = x[1], ylab = y[1])
plot(ecdf(monthlyByCateg[,5]), main = "Recovered Auto", xlab = x[1], ylab = y[1])
```

```
prova <- filter(tots, Description == "ATT: AUTOMOBILE", Year == '2001')
```

```
## Error in filter_(.data, .dots = lazyeval::lazy_dots(...)):  oggetto
"tots" non trovato
```

```
#tipologie di descrizione
n_distinct(tots$Description)
```

```
## Error in n_distinct_multi(list(...), na.rm):  oggetto "tots" non
trovato
```

```
tots.transposed <- t(tots[,3])
```

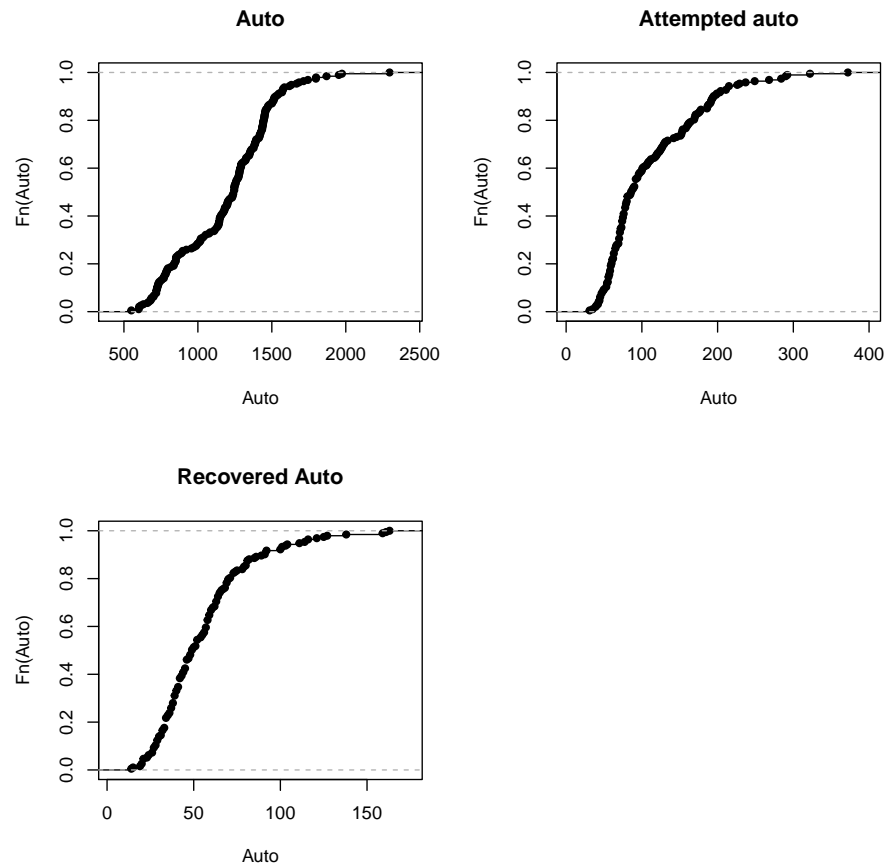
```
## Error in t(tots[, 3]):  oggetto "tots" non trovato
```

```
boxplot(filter(tots, tots$Year == 2005))
```

```
## Error in filter_(.data, .dots = lazyeval::lazy_dots(...)):  oggetto
"tots" non trovato
```

```
qplot(data = tots, x = Year, y = count, )
```

```
## Error in ggplot(data, aesthetics, environment = env):  oggetto "tots"
non trovato
```



Noto immediatamente che il 2017 ha solo 910 furti. Chiaramente essendo il 2017 iniziato da poco, questo valore è da trattare adeguatamente per non sfalsare la nostra analisi.

Ora risulterebbe più interessante accoppiare il totale di ogni anno con le tipologie di furto (colonna **Description**)